

title

Pedro Henrique Oliveira de Souza

7 de março de 2019

Capítulo 14

O capítulo introduz dados de série temporal e correlação temporal. Começa apresentando gráficos com a inflação dos EUA.

A observação da variável Y no momento t se mostra como Y_t . O total de observações é T . O espaço entre t e $t + 1$ é um intervalo abstrato qualquer.

- A variação entre os períodos Y_t e Y_{t-1} é chamada de **primeira diferença**. Ou seja:


$$\Delta Y_t = Y_t - Y_{t-1}$$

É recomendado tomar o *log* das séries temporais. Algumas séries apresentam crescimento aproximadamente exponencial, sendo recomendado por isso. Além disso, desvios padrões de mudas séries temporais econômicas é aproximadamente proporcional ao seu nível, isto é, o desvio padrão pode ser expresso corretamente uma porcentagem do nível das séries. Então o desvio padrão do logaritmo das séries é aproximadamente constante.

O primeiro capítulo considera a inflação e a taxa de desemprego. Seguem os gráficos de ambos.


```
# reproduce Figure 14.1 (b) of the book
plot(as.zoo(UNEMP),
     col = "steelblue",
     lwd = 2,
     ylab = "Logarithm",
     xlab = "Date",
     main = "U.S. Unemployment Rate",
     ylim = c(0,max(UNEMP))) ### Limites
```

U.S. Unemployment Rate



```
plot(as.zoo(INF.Taxa),  
     col = "red",  
     lwd = 2,  
     ylab = "Logarithm",  
     xlab = "Date",  
     main = "U.S. Inflation Rate")
```

U.S. Inflation Rate



A taxa anual de inflação é dada por:

$$INF_t \approx 400[\ln(INF_t) - \ln(INF_{t-1})]$$

Usando esses valores, temos de 2004 para 2005:

```
quants(INF["2004::2005-01"])
```

##		Level	Logarithm	AnnualGrowthRate	X1stLagAnnualGrowthRate
##	2004 Q1	186.7000	5.229503		NA
##	2004 Q2	188.1667	5.237328	3.130018	NA
##	2004 Q3	189.3667	5.243685	2.542830	3.130018
##	2004 Q4	191.4000	5.254365	4.272123	2.542830
##	2005 Q1	192.3667	5.259403	2.015118	4.272123

Autocorrelação

A j-ésima autocovariância de uma série Y_t é a covariância entre Y_t e sua j-ésima defasagem (lag), ou seja:

$$\rho_j = \text{corr}(Y_t, Y_{t-j}) = \frac{\text{cov}(Y_t, Y_{t-j})}{\sqrt{\text{var}(Y_t)\text{var}(Y_{t-j})}}$$

Fazendo os testes de autocorrelação usando a função `afc()`, chegamos aos seguintes resultados: * Para a taxa de inflação, temos:

```
acf(na.omit(INF.Taxa), lag.max = 10, plot = F)
```

```
##  
## Autocorrelations of series 'na.omit(INF.Taxa)', by lag  
##  
## 0.00 0.25 0.50 0.75 1.00 1.25 1.50 1.75 2.00 2.25 2.50  
## 1.000 0.758 0.649 0.657 0.572 0.541 0.521 0.435 0.372 0.334 0.326
```

- Para o desemprego, temos:

```
acf(na.omit(UNEMP.Taxa), lag.max = 10, plot = F)
```

```
##  
## Autocorrelations of series 'na.omit(UNEMP.Taxa)', by lag  
##  
## 0.00 0.25 0.50 0.75 1.00 1.25 1.50 1.75 2.00 2.25  
## 1.000 0.650 0.429 0.264 0.053 -0.029 -0.013 -0.056 -0.182 -0.155  
## 2.50  
## -0.137
```

O que mostra que o desemprego passado tem influência no futuro.

Se a autocorrelação fosse negativa, o resultado implicaria que um resultado positivo um período antes impactaria negativamente no futuro.

14.3 Modelos autorregressivos

Modelo autorregressivo de primeira ordem

Se o objetivo é prever o futuro, nada melhor para isso que o período imediatamente anterior. Sendo assim, se o objetivo for ver a inflação do próximo semestre